SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Sveučilišni prijediplomski studij Elektrotehnika i informacijska tehnologija

RASPOZNAVANJE BIJELIH KRVNIH STANICA KORIŠTENJEM SINTETIČKI GENERIRANIH PODATAKA

Završni rad

Ivona Pranjić

Osijek, 2025. godina

FERIT
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Obrazac Z1P: Obrazac za ocjenu završnog rada na sveučilišnom prijediplomskom studiju

Ocjena završnog rada na sveučilišnom prijediplomskom studiju

Ime i prezime pristupnika:	Ivona Pranjić
Studij, smjer:	Sveučilišni prijediplomski studij Elektrotehnika i informacijska tehnologija, Informacijska i komunikacijska tehnologija
Mat. br. pristupnika, god.	5169, 22.07.2022.
JMBAG:	0165094880
Mentor:	prof. dr. sc. Irena Galić
Sumentor:	dr. sc. Marin Benčević
Sumentor iz tvrtke:	
Naslov završnog rada:	Raspoznavanje bijelih krvnih stanica korištenjem sintetički generiranih podataka
Znanstvena grana završnog rada:	**Umjetna inteligencija (zn. polje računarstvo)**
Zadatak završnog rada:	Istražiti i opisati trenutno stanje u području analize mikroskopskih slika krvnih stanica, s naglaskom na metode klasifikacije bijelih krvnih stanica. Proučiti biološku pozadinu i morfološke karakteristike različitih tipova leukocita (bazofili, neutrofili, eozinofili, limfociti, monociti). Prilagoditi postojeći algoritam za sintetičko generiranje slika kako bi stvarao realistične prikaze različitih tipova bijelih krvnih stanica. Implementirati sustav za kontrolirano variranje parametara generiranja (poput oblika, veličine, teksture i intenziteta bojanja stanica) te generirati opsežan skup sintetičkih podataka. Razviti i trenirati duboku

Datum prijedloga ocjene završnog rada od strane mentora:	03.09.2025.
Prijedlog ocjene završnog rada od strane mentora:	Izvrstan (5)
Datum potvrde ocjene završnog rada od strane Odbora:	10.09.2025.
Ocjena završnog rada nakon obrane:	Izvrstan (5)
Datum potvrde mentora o predaji konačne verzije završnog rada čime je pristupnik završio sveučilišni prijediplomski studij:	11.09.2025.

FERIT
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

IZJAVA O IZVORNOSTI RADA

Osijek, 11.09.2025.

Ime i prezime Pristupnika:	Ivona Pranjić
Studij:	Sveučilišni prijediplomski studij Elektrotehnika i informacijska tehnologija, Informacijske i komunikacijske tehnologije
Mat. br. Pristupnika, godina upisa:	5169, 22.07.2022.
Turnitin podudaranje [%]:	7

Ovom izjavom izjavljujem da je rad pod nazivom**: Raspoznavanje bijelih krvnih stanica korištenjem sintetički generiranih podataka**

izrađen pod vodstvom mentora prof. dr. sc. Irena Galić

i sumentora dr. sc. Marin Benčević

moj vlastiti rad i prema mom najboljem znanju ne sadrži prethodno objavljene ili neobjavljene pisane materijale drugih osoba, osim onih koji su izričito priznati navođenjem literature i drugih izvora informacija.
Izjavljujem da je intelektualni sadržaj navedenog rada proizvod mog vlastitog rada, osim u onom dijelu za koji mi je bila potrebna pomoć mentora, sumentora i drugih osoba, a što je izričito navedeno u radu.

Potpis pristupnika:

Mojem djedu Vinku i baki Mari – vi ste moja najveća podrška, na Zemlji i među zvijezdama.

SADRŽAJ

1. UVOD 1

1.1. Zadatak završnog rada 1

2. BIOLOŠKA POZADINA 2

2.1. Stanice imunosnog sustava 2

2.2. Razlike među tipovima stanica 2

2.2.1. Limfociti 2

2.2.2. Fagociti 3

2.2.3. Posredničke stanice 5

3. PREGLED LITERATURE I TRENUTNO STANJE 6

3.1. Analiza mikroskopskih slika na neautomatizirani način 6

3.2. Automatizacija procesa klasifikacije bijelih krvnih stanica 7

3.3. Trenutni pregled područja 8

4. TEORIJSKA I TEHNIČKA POZADINA 11

4.1. Strojno učenje i njegove vrste 11

4.2. Nadzirano učenje - klasifikacija 11

4.3. Metrike za evaluaciju klasifikacije 12

4.4. Konvolucijske neuronske mreže (CNN) 13

4.5. Prijenosno učenje 15

4.6. Opis korištenih tehnologija 15

4.6.1. TensorFlow 15

4.6.2. Keras 15

4.6.3. Google Colab 16

4.6.4. Kaggle API 16

4.6.5. Scikit-learn 16

4.6.6. Matplotlib i seaborn 16

5. RAZVOJ KLASIFIKACIJSKOG MODELA 17

5.1. Generiranje sintetičkih slika 17

5.2. Izgradnja CNN pomoću prijenosnog učenja 18

6. REZULTATI I ANALIZA MODELA 22

6.1. Opis eksperimentalnih faza **22**
6.1.1. Lokalno treniranje na sintetičkim podacima 22
6.1.2. Testiranje na manjem skupu stvarnih slika 24
6.1.3. Cloud treniranje i testiranje 27
6.2. Utjecaj parametara generiranja sintetičkih podataka **30**
6.3. Evaluacija robusnosti i generalizacije **31**
6.4. Prednosti i ograničenja sintetičkih podataka **33**
7. ZAKLJUČAK **34**
LITERATURA **35**
ŽIVOTOPIS **37**
SAŽETAK **38**
ABSTRACT **39**
PRILOG: PROGRAMSKI KOD **40**

1. UVOD

Bijele krvne stanice jedan su od glavnih pokazatelja slabosti ili ugroženosti imunološkog sustava. Shodno tome, analiza mikroskopskih slika ima ključnu ulogu u medicinskoj dijagnostici, omogućujući identifikaciju i klasifikaciju različitih tipova stanica. Precizna klasifikacija leukocita, poput bazofila, neutrofila, eozinofila, limfocita i monocita ima primjenu u otkrivanju i praćenju bolesti npr. leukemije, anemije i različitih infekcija.

Tradicionalne metode analize mikroskopskih slika zahtijevaju ručnu obradu i analizu stručnjaka, što je vremenski zahtjevno i postoji sklonost ljudskim pogreškama. Razvojem umjetne inteligencije, strojnog učenja i tehnika treniranja neuronskih mreža proces analize postaje automatski s puno manjim nepreciznostima i bržim rezultatima. Međutim, treniranje modela dubokog učenja zahtijeva jako velike i raznolike skupove podataka što je ograničeno slabom dostupnosti kvalitetnih mikroskopskih slika.

Jedno od rješenja ovog problema jest generiranje sintetičkih skupova podataka. Ovim pristupom se povećava dostupnost podataka za korištenje i treniranje neuronske mreže. Sintetički podatci pružaju kontrolu različitih parametara poput oblika, veličine, teksture i intenziteta bojanja stanica, čime omogućuju ostvarivanje sličnosti ka stvarnim mikroskopskim slikama.

Ovaj rad u prvom redu prikazuje pregled trenutnog stanja u području analize mikroskopskih slika, zatim se bavi tehničkom i biološkom stranom generiranja i evaluacije podataka. Na kraju analizira učinkovitost i primjenjivost razvijenog sustava, a sve u cilju usporedbe sa stvarnim kliničkim podacima i donošenjem zaključka.

1.1. Zadatak završnog rada

Zadatak ovog završnog rada jest istražiti i opisati trenutno stanje u području analize mikroskopskih slika krvnih stanica, s naglaskom na metode klasifikacije bijelih krvnih stanica. Potrebno je prilagoditi postojeći algoritam za sintetičko generiranje različitih tipova bijelih krvnih stanica kako bi se stvorili slikovni skupovi uz zadane parametre. Zatim treba koristiti te skupove za treniranje postojeće arhitekture neuronske mreže za klasifikaciju tipa bijele krvne stanice. Na kraju, istražiti utjecaj parametara generiranja slika na rezultate klasifikacije stvarnih mikroskopskih slika. Tehnologije koje se koriste su Python, PyTorch/TensorFlow, OpenCV i scikit-image.

2. BIOLOŠKA POZADINA

Imunološki sustav jest jedan od najvažnijih organskih sustava u tijelu čovjeka. Vjerojatno zbog svoje višestruke uloge, on nije poput ostalih organskih sustava, uobličen u anatomski jasno definiran i ograničen sustav, nego je raspoređen gotovo svuda u tijelu. Sastoji se od limfnih organa, tkiva i cirkulirajućih sastojaka, odnosno stanica i topljivih posrednika imunosti.[1]

2.1. Stanice imunosnog sustava

Osnovna podjela stanica imunosnog sustava jest na limfatičke i mijeloičke stanice. Limfatičke stanice, koje predstavljaju glavni faktor u specifičnoj (adaptivnoj) imunosti, možemo podijeliti na limfocite T, limfocite B i prirodnoubilačke (NK) stanice. S druge strane, mijeloičke stanice su ključne za nespecifičnu (urođenu) imunost, a razlikujemo fagocite (granulocite, neutrofile, eozinofile, monocite) i posredničke stanice (bazofile, mastocite i trombocite).[1] Jasna podjela prikazana je na Slika 2.1. uz jednostavni grafički prikaz različitih vrsta i oblika bijelih krvnih stanica.

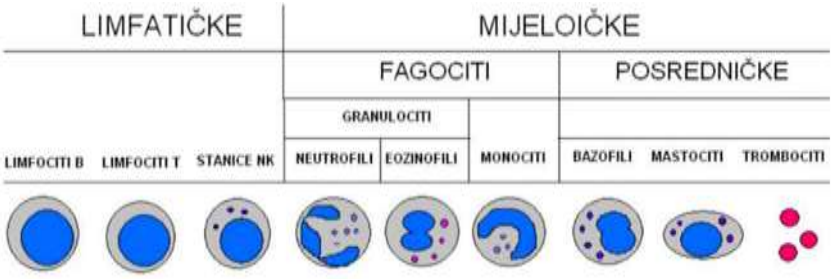

Slika 2.1. Podjela stanica imunosnog sustava

2.2. Razlike među tipovima stanica

2.2.1. Limfociti

Limfociti su najmanje stanice u krvi koje imaju obrambenu ulogu. Dvije glavne skupine limfocita su limfociti T i B. Njihova glavna uloga jest proizvodnja antitijela koji djeluju na patogene uzroke bolesti i infekcija u organizmu. Obje vrste nastaju u koštanoj srži, ali limfociti B tamo i sazrijevaju dok tip T sazrijeva u timusu. Osim ove dvije skupine, razlikujemo i prirodnoubilačke ili NK (engl. Natural killer) stanice.[1] Ono što je nama zanimljivo u okviru njihovog raspoznavanja u

mikroskopskim slikama jest da ove tri vrste nemaju značajne razlike morfološki, nego samo u svojim funkcionalnostima.(Slika 2. 2, Slika 2. 3.)

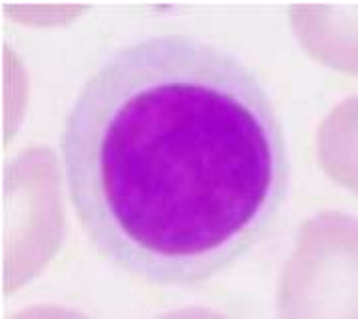

Slika 2. 2. Limfocit iz razmaza ljudske periferne krvi

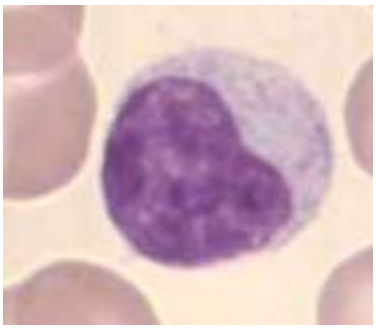

Slika 2. 3. Stanica NK iz razmaza ljudske periferne krvi

2.2.2. Fagociti

Fagocite u principu dijelimo na granulocite i monocite. Granulocite još dijelimo na neutrofile i eozinofile. Granulociti su specifični po tome što sadrže granule u citoplazmi. Općenito, granulociti imaju poseban oblik koji se uspoređuje sa jedrom. Uglavnom je jedro sastavljeno od tri segmenta, odnosno režnja. Neutrofili ili neutrofilni granulociti su najbrojniji od svih leukocita u krvi, čine čak 90% granulocita u perifernoj krvi.[1] Obilježavaju ih segmentirana jezgra i prisutnost dviju vrsta citoplazmatskih granula (Slika 2. 4).

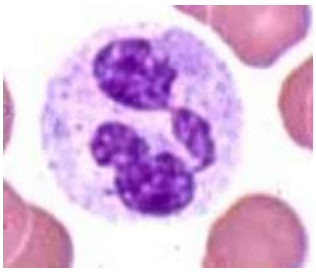

Slika 2. 4 Neutrofilni granulocit (razmaz periferne krvi)

Eozinofilni granulociti čine 2 – 5% granulocita u perifernoj krvi. Prema morfologiji i veličini slični su neutrofilima. Okruglog su oblika, jezgra im je podijeljena u dva segmenta, a na površini imaju kratke nastavke slične mikroresicama (Slika 2. 5).[1]

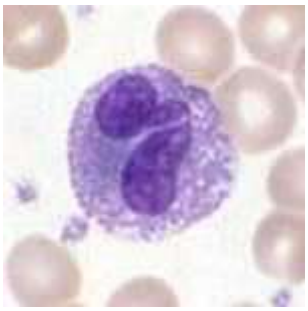

Slika 2. 5 Eozinofilni granulocit (razmaz periferne krvi)

Monociti su krupne, odnosno najveće stanice u krvi. Jedro im je bubrežastog oblika i za razliku od granulocita, nije segmentirano. U citoplazmi se nalaze granule sa enzimima (Slika 2. 6).[1]

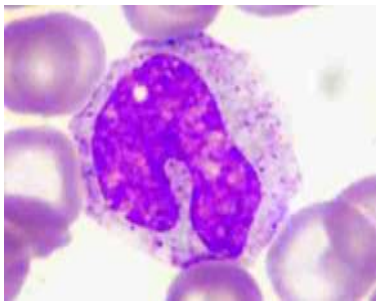

Slika 2. 6 Monocit (razmaz periferne krvi)

2.2.3. Posredničke stanice

U skupinu posredničkih stanica ubrajamo bazofile, mastocite i trombocite. Što se tiče bazofila, njih u krvi ima manje od 0,2 %, a obilježava ih tamnoljubičasta citoplazmatska granula. Često ih se ne može razlučiti od mastocita (Slika 2. 7 Slika 2. 8).[1]

Slika 2. 7 Bazofil (razmaz periferne krvi)

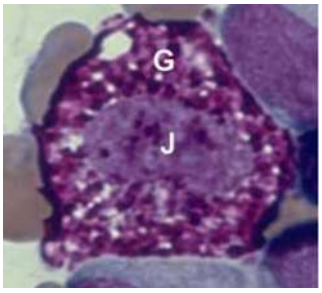

Slika 2. 8 Mastocit s granulama (G) i odvojenom jezgrom (J) (razmaz periferne krvi)

Posljednja vrsta posredničkih stanica su trombociti (Slika 2. 9), za koje se veže uloga u koagulaciji odnosno zgrušavanju krvi. Oni se opisuju kao tzv. krvne pločice, malena bezbojna tijela bez jezgre. Imaju loptast, ovalan oblik, a ako izvjesno vrijeme stoje u izvađenoj krvi čije je zgrušavanje spriječeno dobiju vretenasti oblik.[1]

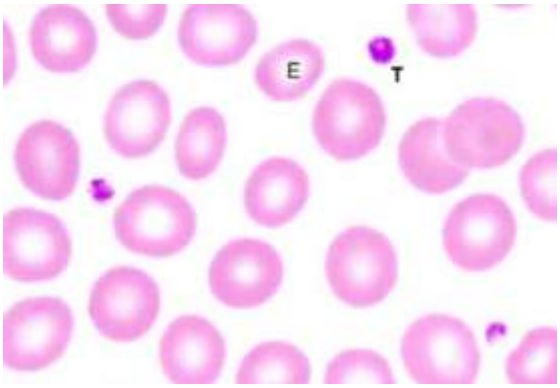

Slika 2. 9 Trombocit (T) u veličinskoj usporedbi s eritrocitom (E) iz heparinizirane ljudske krvi

3. PREGLED LITERATURE I TRENUTNO STANJE

U 3. poglavlju ovog završnog rada, fokus će biti na pregledu dostupne literature u području, te na evaluaciji do sada korištenih metoda u analizi mikroskopskih slika bijelih krvnih stanica. Počet ćemo sa neautomatiziranim, tradicionalnim metodama, a u nastavku ćemo se osvrnuti na trenutno dostupne automatizirane procese te njihov značaj i doprinos u ovoj grani medicinske dijagnostike.

3.1. Analiza mikroskopskih slika na neautomatizirani način

Segmentacija bijelih krvnih stanica na digitalnim slikama hematoloških mikroskopa ključna je metoda za dijagnosticiranje i procjenu bolesti i poremećaja krvi. U području hematologije i histopatologije, patološki pregledi i dalje su zlatni standard te imaju presudnu ulogu u postavljanju dijagnoza. Tijekom kliničke analize, patolozi proučavaju bijele krvne stanice koristeći uzorke perifernih krvnih razmaza pacijenata. Ta analiza temelji se na morfološkim obilježjima bijelih krvnih stanica i njihovih struktura, poput jezgre i citoplazme, uključujući oblik, veličinu, boju, teksturu, stupanj zrelosti te procese bojenja. [2] (Slika 3. 1)

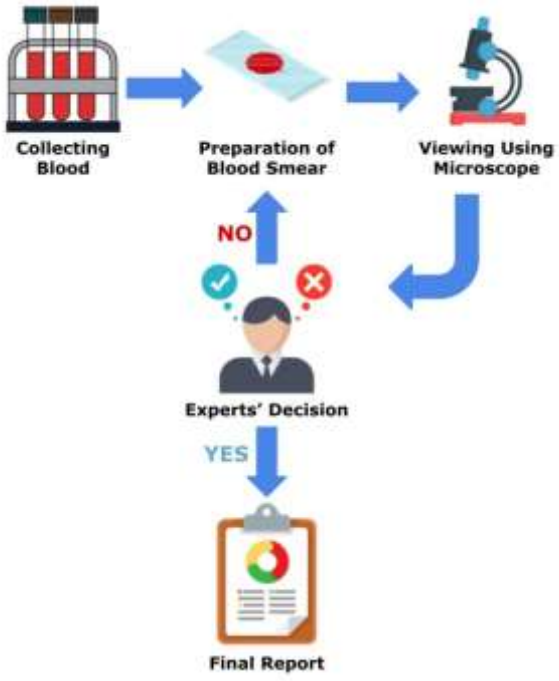

Slika 3. 1 Postupak ručnog otkrivanja i segmentacije komponenata bijelih krvnih stanica

Slika 3. 1 jasno prikazuje kako ključni dio posla zapravo izvršava čovjek, profesionalac u tom području, odnosno doktor medicine. Prvi nedostatak koji možemo zamijetiti u ovakvom pristupu jest dug vremenski period koji je potreban kako bi se došlo do konačnog rezultata. U jako velikom broju slučajeva, rezultati medicinske dijagnostike, odnosno medicinski nalazi su potrebni u što skorijem vremenu, kako bi se moglo pokrenuti liječenje određene bolesti. Kada bismo uspjeli maksimalno smanjiti čekanje rezultata analize, mogli bismo gotovo odmah po prijemu kod liječnika, započeti s liječenjem bolesti. Ovo bi pokrenulo brže reakcije na neke terminalne bolesti poput tumora, raka, AIDS-a ili sl.

Sljedeći problem koji se nameće u tradicionalnom laboratorijskom pristupu jest kakvoća i točnost krajnjih rezultata. Ponovno, zbog direktnog ljudskog utjecaja na konačne rezultate, očekujemo visoku stopu mjerne nesigurnosti, odnosno netočnosti. Iako se radi o visoko stručnim osobama koje izvršavaju ovaj proces, korištenjem umjetne inteligencije, računala i neuronskih mreža, krajnje rješenje bi imalo gotovo nezamjetnu stopu pogreške, te bi doktori puno dublje razumjeli krvnu sliku pacijenta te tako odredili konačnu dijagnozu.

3.2. Automatizacija procesa klasifikacije bijelih krvnih stanica

Klasifikacija slika uključuje proces segmentacije, koja podrazumijeva podjelu slike na povezane regije koje ne preklapaju jedna drugu, a svaka od njih odgovara važnim anatomskim dijelovima. Ona predstavlja jedan od najvažnijih koraka u procesu klasifikacije slika, jer segmentacijom otkrivamo pojedinačne strukture i karakteristike koje razlikuju naizgled slične uzorke. Automatizirani procesi koji se koriste segmentacijom za otkrivanje i klasifikaciju našli su primjenu u različitim disciplinama kao npr. satelitsko snimanje, biometrijsko prepoznavanje, prepoznavanje teksta i govora te medicinsko snimanje. Međutim, u području medicinske dijagnostike, segmentacija slika je iznimno izazovna zbog šuma u slikama i prisutnosti više anatomskih struktura koje su često odvojene vrlo uskim granicama. Iako je ovo područje istraživanja u fokusu desetljećima, univerzalna rješenja za sve vrste medicinskih slika i struktura još uvijek nisu dostupna.

U analizi medicinskih slika, klasifikacija ima ključnu ulogu, posebice u kontekstu mikroskopskih slika u hematologiji i histopatologiji. Cilj je osigurati brze i pouzdane metode za preciznu identifikaciju regija na slikama te klasne podjele prema vrsti stanica. Napredne tehnike iz obrade slika, računalnog vida, strojnog učenja i dubokog učenja sve su češće korištene za ovu svrhu. Među

značajnim su primjena konvolucijskih neuronskih mreža (CNN) za analizu tumora mozga na MR slikama, klasifikacija tumora dojke temeljena na grafovima u ultrazvučnim slikama i sl.[3]

Kod bijelih krvnih stanica, segmentacija njihovih jezgara i citoplazme ključan je korak u dijagnosticiranju bolesti, klasifikaciji stanica, njihovom brojanju i određivanju stadija bolesti. Jezgre bijelih krvnih stanica posebno su važne za razumijevanje prisutnosti bolesti i procjene njezine ozbiljnosti, npr. kod karcinoma, tumora, AIDS-a, anemije i sl.

3.3. Trenutni pregled područja

Tijekom posljednjih dvadeset godina ostvaren je značajan napredak u ovom području. Tradicionalne metode temelje se na ručnoj analizi mikroskopskih slika, kao što je već spomenuto, što povećava mogućnost pogrešaka. Zbog toga je razvoj automatiziranih i računalno potpomognutih sustava postao ključan za precizno, sustavno, nepristrano i brzo postavljanje kliničkih dijagnoza te za učinkovitije provođenje terapije.

Postoje dvije glavne metode koje se uobičajeno koriste za automatiziranu klasifikaciju bijelih krvnih stanica na slikama razmaza krvi: tradicionalne metode strojnog učenja (eng. *machine learning* ili ML) i metode dubokog učenja(eng. *deep learning* ili DL). Računalno potpomognuti sustavi mogu analizom leukocita automatski dijagnosticirati različite hematološke bolesti, poput HIV-a i leukemije.

Tradicionalni pristup strojnog učenja uključuje niz međusobno povezanih koraka, počevši od segmentacije regije koja nas zanima, preko izdvajanja značajki, do završnog koraka klasifikacije. Izdvajanje značajki je posebno izazovno i ima izravan utjecaj na uspješnost klasifikacije. U posljednje vrijeme, sve se češće primjenjuju metode dubokog učenja zbog veće učinkovitosti i vrlo jednostavne primjene. Napredne tehnike dubokog učenja, osobito one koje koriste prijenosno učenje (eng. *transfer learning*), dodatno su unaprijedile razvoj automatiziranih sustava za klasifikaciju bijelih krvnih stanica. [4]

Osnovni korak kod klasifikacije s modelima strojnog i dubokog uključuje predobradu podataka, odabir i izvlačenje značajki. Različit je pristup kod tradicionalnog strojnog učenja i dubokog učenja upravo u ovom dijelu procesa klasifikacije što možemo vidjeti na slici (Slika 3. 2).

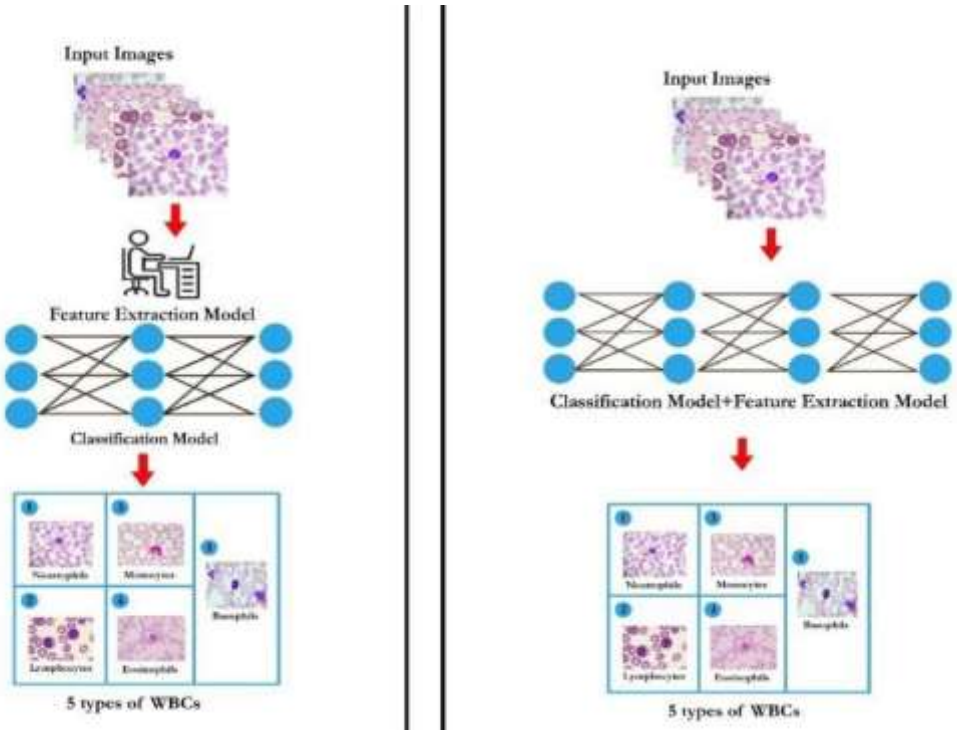

a) b)

Slika 3. 2 Klasifikacija slika neutrofila: a) tradicionalni model strojnog učenja, b) napredni model dubokog učenja

Dakle, prema slici možemo vidjeti kako kod pristupa gdje se koristi tradicionalni model strojnog učenja ekstrakciju značajki radi čovjek, stručnjak koji se bavi izgradnjom i treniranjem modela. Takav pristup je dosta spor i može uključivati određenu pogrešku i pristranost osobe koja odrađuje taj proces. Kod dubokog učenja pak imamo nešto drugačiji pristup – sama neuronska mreža, odnosno model kojeg koristimo za klasifikaciju, uči značajke ulaznih podataka te ih ekstrahira. Ovaj pristup donio je puno bolje rezultate, s većim postotcima metrika koje računamo pri evaluaciji klasifikacije, što pokazuje učinkovitost korištenja dubokog učenja kod ovakvih problema. Većina znanstvenika koristi tri parametra za evaluaciju performansi: točnost, osjetljivost i specifičnost. [5] Ti parametri se računaju koristeći sljedeće formule(Formula 8, 2 , 3):

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{1}$$

Formula 1

$$Sensitivity = \frac{TP}{TP + FN} \tag{2}$$

Formula 2

$$Specificity = \frac{TN}{TN + FP} \tag{3}$$

Formula 3

Što se tiče predobrade podataka za klasifikaciju i obradu modelima strojnog učenja, ona igra krucijalnu ulogu. Predobrada podataka omogućuje točnu i preciznu klasifikaciju, odnosno ostvarivanje visokih ranije navedenih i drugih metrika, koje evaluiraju model. Rosyadi i drugi [5] su koristili optički mikroskop kako bi generirali uzorke krvi za slike stanica. Metoda se sastojala od predobrade slika, segmentacije, izdvajanja značajki te klasifikacije. Također, u svom izvještaju, Rosyadi i drugi su koristili različite geometrijske značajke koje su im pomogle u fazi izvlačenja značajki i koje smatraju važnima za ovu vrstu klasifikacije. To su: normalizirano područje, solidnost, ekscentričnost, cirkularnost te normalizirani opseg. Kroz ove karakteristike su uspjeli diferencirati bijele krvne stanice kroz algoritam k – srednjih vrijednosti (eng. *K – means clustering algorithm*). Rezultati su pokazali da geometrijsko svojstvo cirkularnosti ima najveću važnost pri klasifikaciji, te su ostvarili točnost od 67%. [4-5]

Tai i drugi [6] su odradili višeklasnu klasifikaciju pomoću metode stroja potpornih vektora ili SVM (eng. *support vector machine*). Eksperimentom su obavili hijerarhijsku identifikaciju i klasifikaciju bijelih krvnih stanica, što se pokazalo kao vrlo uspješan pristup ovakvom problemu. Došli su do zaključka da ovakva metoda nadilazi dosadašnje manualno prepoznavanje tih stanica, te su ostvarili značajan rezultat točnosti od čak 95,3%.

Još jedna metoda koja se pokazala kao veliki doprinos u području raspoznavanja bijelih krvnih stanica jest PCA ili analiza glavnih komponenata (eng. *Principal Component Analysis*). Yampri i drugi [7] su koristili PCA kako bi smanjili dimenzionalnost svojstvenim prostorima ulaznih slika, što je dovelo do točnosti od 92% na testnom skupu.

Navedeni modeli, istraživanja i eksperimenti su samo neki od pristupa koji se mogu koristiti u ovom području. Svi oni zapravo sadrže svoje prednosti pristupa, ali i mane koji ih još ne čine dovoljno primjenjivima u konkretnoj medicinskoj dijagnostičkoj praksi. Nedostatci uključuju u prvom redu nedostatak lako dostupnih, kvalitetnih i dovoljno velikih setova podataka na kojima bi se mogli trenirati, validirati i testirati modeli strojnog učenja te manjak medicinskih stručnjaka koji su posvećeni ovom području.[4] Zaključci većine radova u području predlažu korištenje modela dubokog učenja u kombinaciji sa prijenosnim učenjem, što će se obraditi i evaluirati u praktičnom dijelu ovog rada.

4. TEORIJSKA I TEHNIČKA POZADINA

4.1. Strojno učenje i njegove vrste

Strojno učenje predstavlja jedan dio širokog područja kojeg nazivamo umjetna inteligencija (eng. *artificial intelligence*). Područje strojnog učenja možemo podijeliti na 3 grane ili tipa:

1. Nadzirano učenje (eng. *Supervised Learning*): Model uči iz označenih trening podataka te za cilj ima odrediti nepoznatu funkcionalnu ovisnost između ulaznih veličina i izlazne veličine na temelju podatkovnih primjera. Najčešći problemi uključuju regresiju i klasifikaciju.
2. Nenadzirano učenje (eng. *Unsupervised Learning*): Koriste se neoznačeni podaci za trening modela, a cilj je otkrivanje skrivenih zakonitosti ili obrazaca u podacima. Problemi u nenadziranom učenju uključuju smanjivanje dimenzionalnosti podataka te grupiranje (klasteriranje) podataka.
3. Podržano učenje (eng. *Reinforcement Learning*): Cilj je razviti sustav (agenta) koji poboljšava svoje performanse na temelju interakcije s okolinom.

4.2. Nadzirano učenje - klasifikacija

U okviru nadziranog strojnog učenja može se govoriti o 2 glavna problema, a to su regresija i klasifikacija. Broj ulaznih veličina označava se s n, pa se vektor ulaznih veličina može zapisati kao:

$$x^{(i)} = [x_1^{(i)}, \dots, x_n^{(i)}]^T \tag{4}$$

Jednadžba 4

Raspoloživi podatkovni primjeri (mjerni uzorci) na temelju kojih se određuje nepoznata funkcionalna ovisnost često se nazivaju i skup za učenje (Jednadžba):

$$\{(x^{(1)}, y^{(1)}), \dots, (x^{(ntrain)}, y^{ntrain})\} \tag{5}$$

Jednadžba 5

Ako je veličina y diskretna, tada se ovaj problem naziva klasifikacija, a ako je y kontinuirana veličina onda govorimo o regresiji.

U kontekstu klasifikacije razlikujemo binarnu i višeklasnu klasifikaciju. Binarna klasifikacija razvrstava podatke na izlazu u dvije različite klase, dok višeklasna klasifikacija, kako i sam naziv sugerira, svrstava podatke u više klasa.

4.3. Metrike za evaluaciju klasifikacije

Kako bismo odredili kakvoću modela strojnog učenja i donijeli sud o njegovim performansama, koristimo se različitim metrikama. Za probleme klasifikacije najčešće koristimo matricu zabune (eng. *Confusion matrix*). Matrica zabune (Slika 4. 1) svrstava izlazne podatke iz modela u 4 kategorije:

- Stvarno pozitivan (eng. *true positive*) (TP),
- Stvarno negativan (eng. *true negative*) (TN),
- Lažno pozitivan (eng. *false positive*) (FP),
- Lažno negativan (eng. *false negative*) (FN).

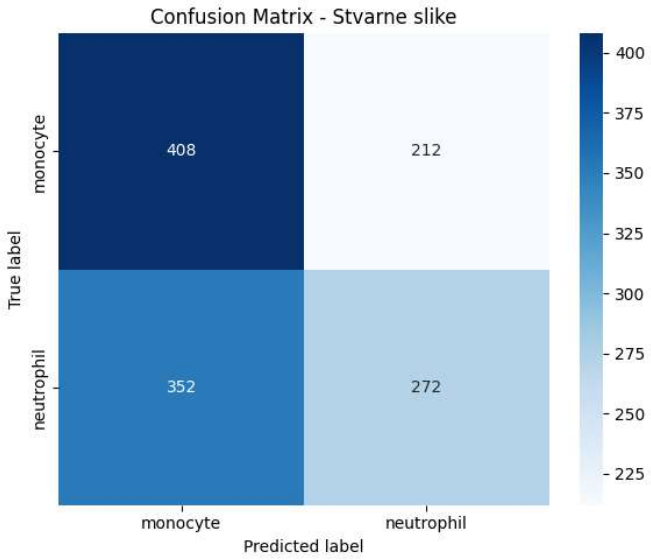

Slika 4. 1 Primjer matrice zabune

Ovisno o tim kategorijama, odnosno parametrima matrice zabune, razlikujemo 4 osnovne klasifikacijske metrike:

1. Preciznost (eng. *precision*): Govori nam koliko je model „pogodio“ za sve podatke za koje je rekao da pripadaju određenoj klasi. Vrlo pogodna mjera kada nam je „cijena“ FP previsoka.

$$Precision = \frac{TP}{TP + FP} \tag{6}$$

Formula 6

2. Odziv (eng. *recall*): Pogodna mjera kada je veoma bitan broj FN.

$$Recall = \frac{TP}{TP + FN} \tag{7}$$

Formula 7

3. Točnost (eng. *accuracy*): Omjer stvarnih oznaka naspram svih ostalih. Ima smisla mjeriti za balansirani skup, odnosno skup u kojem imamo podjednako raspoređene članove klasa.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{8}$$

Formula 8

4. F1 mjera: Predstavlja harmonijsku sredinu preciznosti i odziva. Mjeri se kada je potreban balans između te dvije mjere.

$$F1 = 2x\frac{precision\ x\ accuracy}{precision + accuracy} \tag{9}$$

Formula 9

4.4. Konvolucijske neuronske mreže (CNN)

Konvolucijska neuronska mreža (eng. *Convolutional Neural Network, CNN*) je vrsta neuronske mreže koja se sastoji od niza slojeva – konvolucijski slojevi, slojevi sažimanja (eng. *pooling layers*), potpuno povezani (eng. *dense*) slojevi, itd. Karakteristika koja je iznimno važna kod CNN-a (Slika 4. 2) jesu efikasno posloženi slojevi koji uzimaju u obzir da je ulazni podatak slika – neuroni su posloženi u tri dimenzije (širina, visina i dubina).

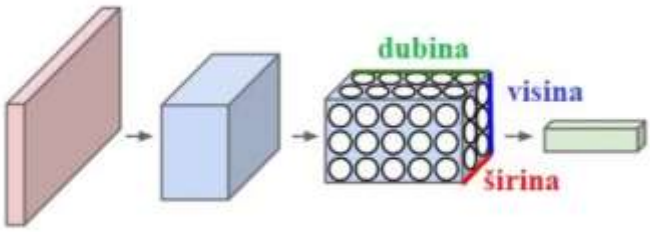

Slika 4. 2 Konvolucijska neuronska mreža

Osnovu kovolucijske mreže čini konvolucijski sloj. Njegovom primjenom zadržava se prostorna struktura ulaznih podataka. Konvolucijski sloj svoj naziv dobio je po tome što se u njemu primjenjuje operacija konvolucije nad ulaznim podacima – odvija se „pomicanje“ filtra po slici i računanje skalarnog produkta. Težina filtra w te pristranost (eng. *bias*) b su parametri mreže te se mogu mijenjati tijekom učenja. Primjenom istog filtra na različitim pozicijama na slici dobiva se tzv. aktivacijska mapa. Aktivacijska mapa je dvodimenzionalna matrica koja kao podatak sadrži odzive filtra na pojedinom dijelu ulazne slike. Svi neuroni aktivacijske mape imaju zajedničke parametre, što zapravo u odnosu na potpuno povezane slojeve čini puno manji broj parametara koji se treniraju.

CNN se zasniva na sekvenci konvolucijskih slojeva između kojih se naravno nalaze aktivacijske funkcije. Najčešće su korištene ReLU aktivacijske funkcije na izlazu iz pojedinog sloja. Osim konvolucijskih, često su korišteni i slojevi sažimanja. Njihov zadatak jest da drže reprezentaciju slike što manjom, a primjenjuju se na svaku aktivacijsku mapu posebno.

Sažimanje jest operator kojim se više vrijednosti u aktivacijskoj mapi zamjenjuje jednom vrijednošću, čime se postiže smanjivanje detaljnosti u toj mapi. Također, važno je napomenuti kako ovaj sloj nema parametre koji se određuju postupkom učenja.

Složenije konvolucijske neuronske mreže mogu biti od velike memorijske i računalne zahtjevnosti i potrošnje, što predstavlja ograničenja resursa za njihovo korištenje. Postoji nekoliko načina kako smanjiti zahtjeve CNN, s prihvatljivim gubitkom na preciznosti klasifikacije, a jedan od njih jest metoda prijenosnog učenja korištena u radu.

4.5. Prijenosno učenje

Prijenosno učenje je tehnika strojnog učenja u kojoj se znanje stečeno kroz jedan zadatak ili skup podataka koristi za poboljšanje performansi modela na drugom povezanom zadatku ili skupu podataka. Odnosno, prijenosnim učenjem model koristi ono što je naučio u jednom okruženju kako bi poboljšao generalizaciju u drugom okruženju. [8]

Tradicionalni pristupi učenja zalažu se da za svaki novi zadatak se gradi novi model na temelju dostupnih označenih podataka. To je zato što tradicionalni algoritmi strojnog učenja pretpostavljaju da dostupni podaci za treniranje i testiranje potječu iz istog prostora značajki, pa ako se naučeni model primijeni na novi skup podataka, treniranje slojeva se mora odraditi ponovno od nule, čak i ako se radi o vrlo sličnom novom zadatku.

Ali, algoritmi korišteni kod prijenosnog učenja uzimaju upravo već naučene modele kao polazišnu točku. Oni primjenjuju znanje tog modela na novi, ali sličan zadatak. Kod analize praktičnog dijela rada govorit će se više o prednostima i razlikama između klasične konvolucijske mreže i korištenja predtrenirane mreže pomoću prijenosnog učenja.

4.6. Opis korištenih tehnologija

Slijedi kratki opis tehnologija korištenih u praktičnom dijelu izrade rada.

4.6.1. TensorFlow

TensorFlow je softverska biblioteka za strojno učenje i umjetnu inteligenciju. Njegova primjena je dosta široka, ali se uglavnom koristi za treniranje i učenje modela neuronskih mreža. [9] Jedan je od najpopularnijih okvira za stvaranje modela dubokog učenja, a osim njega često se koristi i PyTorch. Softver je potpuno besplatan, a razvijen je pod okriljem Google Brain tima s ciljem interne upotrebe za istraživanja i proizvodnju tvrtke Google. TensorFlow se može koristiti u širokom rasponu programskih jezika kao što su Python, JavaScript, C++, Java, što njegovo korištenje čini laganim i primjenjivim u mnogim sektorima.

4.6.2. Keras

Keras je biblioteka za izgradnju neuronskih mreža koja omogućava jednostavno i lako definiranje modela. [10] Zahvaljujući svojoj strukturi, omogućava brzo kreiranje, treniranje i evaluaciju modela bez potrebe za detaljnim upravljanjem kompleksnim matematičkim operacijama u pozadini. U sklopu ovog rada, Keras je korišten kao sučelje unutar TensorFlow okvira za definiranje i treniranje izgrađenog modela.

4.6.3. Google Colab

Google Colab je *cloud-based* razvojno okruženje koje omogućava izvođenje Python koda bez potrebe za lokalnim računalnim resursima. Pruža besplatan pristup grafičkim (GPU) i tenzorskim (TPU) procesorima, što ga čini posebno pogodnim za zahtjevne zadatke poput treniranja dubokih neuronskih mreža. [11] Kroz zadatak klasifikacije bijelih krvnih stanica, Google Colab je korišten za preuzimanje velikog podatkovnog skupa, te za treniranje i evaluaciju modela strojnog učenja.

4.6.4. Kaggle API

Kaggle API omogućava jednostavan i automatiziran pristup brojnim javno dostupnim skupovima podataka, što značajno olakšava rad sa stvarnim podacima u području strojnog učenja. Kroz jednostavne naredbe moguće je preuzeti, organizirati i koristiti velike skupove podataka direktno iz *cloud* okruženja, bez potrebe za ručnim preuzimanjem i lokalnim pohranjivanjem podataka. [12] U ovom radu, Kaggle API je korišten za preuzimanje skupa podataka leukocita direktno u Google Colab okruženje.

4.6.5. Scikit-learn

Scikit-learn je popularna Python biblioteka koja omogućava jednostavnu primjenu različitih metoda strojnog učenja, statističke evaluacije i analize podataka. Posebno je korisna za izračunavanje metrika uspješnosti modela, kao što su točnost, preciznost, odziv i F1-mjera, ali i za generiranje matrica zabune. [13] Scikit-learn je korišten za evaluaciju performansi klasifikacijskog modela nakon treniranja i testiranja.

4.6.6. Matplotlib i seaborn

Matplotlib je široko korištena Python biblioteka za vizualizaciju podataka, koja pruža jednostavno generiranje različitih grafova i dijagrama. [14] Korištena je za vizualnu reprezentaciju treniranja modela kroz metrike gubitka i točnosti kroz epohe. Seaborn je nadogradnja na Matplotlib koja dodatno olakšava izradu na oko privlačnih i estetskih grafova. [15] Pomoću Seaborn biblioteke vizualizirane su klasifikacijske metrike u obliku stupčastih dijagrama, kao i matrice zabune, što je omogućilo jednostavniju i bolju analizu performansi modela.

5. RAZVOJ KLASIFIKACIJSKOG MODELA

Sljedeće poglavlje bavit će se praktičnim dijelom izrade rada – od stvaranja sintetičkih slika za klasifikaciju do opisa korištenog modela uz prijenosno učenje.

5.1. Generiranje sintetičkih slika

Za potrebe generiranja sintetičkih slika korišten je već postojeći algoritam *gen_blob.py*. [16] Generiranje sintetičkih slika stanica neutrofila i monocita potrebnih za klasifikaciju započinje se generiranjem konture, obruba stanice. Stvara se prazna slika pomoću *numpy* niza zadane veličine u funkciji *generate_blob_image* . Zatim slijedi generiranje pozadine, odnosno svega što nije bijela krvna stanica, što u našem slučaju predstavlja crvene krvne stanice i jednobojno pozadinsko osvjetljenje. Generira se nasumičan broj krvnih stanica koje se postavljaju na također nasumične koordinate slike. Boja pozadine je svijetlo narančasta, a dodatni prostor omogućava da se dijelovi krvnih stanica nalaze izvan granica slike, što čini prikaz još realnijim i vjerodostojnijim. Nakon izrađene pozadine, prelazimo na funkcije koje generiraju stanice monocita (*generate_monocyte*) (Slika 5. 2) i neutrofila (*generate_neutrophile*) (Slika 5. 1). Obje funkcije prvo obrađuju konture stanice, a zatim varijablom *underlayer* se stvara sintetička citoplazma. Na nju se primjenjuje tzv. *papar šum* u različitom omjeru, ovisno o vrsti stanice koja se generira. Sličan proces se ponavlja i za generiranje slike jezgre stanice, nakon čega se spaja sve u cjelinu funkcijama *generate_neutrophil_image* i *generate_monocyte_image*, a slika se skalira na veličinu prikladnu za izlaz. [16]

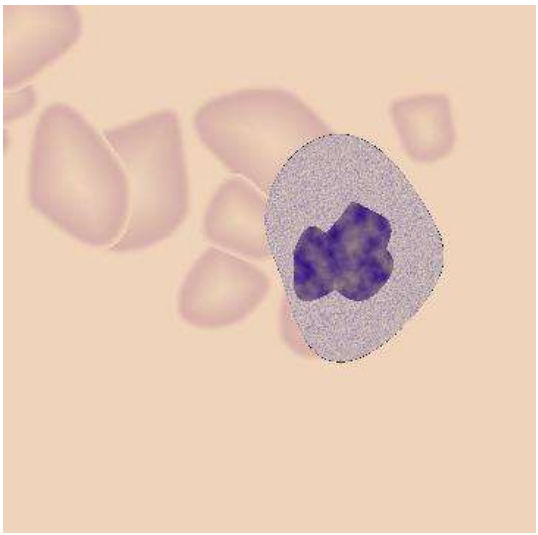

Slika 5. 1 Sintetička slika stanice neutrofila

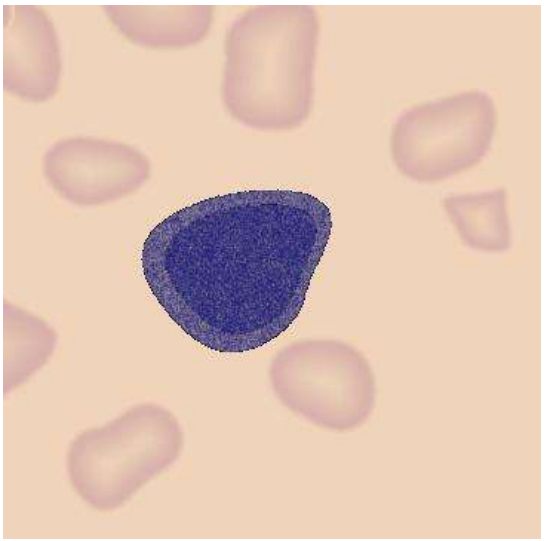

Slika 5. 2 Sintetička slika stanice monocita

Za potrebe ovog projekta generirano je ukupno 200 slika, 100 slika stanica monocita te 100 slika stanica neutrofila, čime je za početak osigurano da imamo balansiran skup za treniranje modela neuronske mreže.

5.2. Izgradnja CNN pomoću prijenosnog učenja

U prethodnom poglavlju dan je opis samog pojma prijenosnog učenja. Naime, njegovim korištenjem moguće je ostvariti puno bolje i značajnije rezultate treniranja neuronske mreže, nego izgradnjom novog modela od nule. Odabrani model za prijenosno učenje je MobileNetV2.

MobileNetV2 je jednostavna i optimizirana konvolucijska neuronska mreža razvijena za rad na uređajima s ograničenim računalnim resursima, čime pritom zadržava vrlo dobre performanse u klasifikacijskim zadacima. Njena specifičnost leži u tzv. *inverted residual* blokovima i *depthwise separable convolution* tehnikama, koje značajno utječu na smanjenje broja parametara i vrijeme treniranja, bez značajnijeg gubitka preciznosti. Upravo zbog svojih dobrih karakteristika, MobileNetV2 predstavlja optimalan izbor za rad s manjim skupovima podataka i kada su dostupni ograničeni hardverski resursi, kao što je ovdje slučaj. Prijenosno učenje omogućilo je da se već unaprijed naučene značajke iz velike baze slika ImageNet iskoriste kao početna točka, što značajno ubrzava učenje i poboljšava rezultate na malom sintetičkom skupu za treniranje.

```
83:     from tensorflow.keras.applications import MobileNetV2

87:     mobilenet =
88:     tf.keras.applications.MobileNetV2(input_shape=(IMG_SIZE,IMG_SIZE,3),
89:     include_top=False,
        weights='imagenet')
```

Programski kod 1 Isječak programskog koda učitavanja MobileNetV2

Kako bi model bio prilagođen konkretnoj klasifikaciji stanica, izvorni klasifikacijski slojevi modela su uklonjeni (korištenjem parametra *include_top=False*), a na njihovo mjesto dodani su novi slojevi specifično definirani za ovaj zadatak.

Na izlaz iz baznog MobileNetV2 modela nadodan je sloj sažimanja (*GlobalAveragePooling2D*), čime se smanjuje broj parametara, a istovremeno smanjuju prostorne značajke iz konvolucijskih slojeva. Nakon toga, nadodano je nekoliko potpuno povezanih (*Dense*) slojeva s aktivacijskom funkcijom na izlazu (ReLU). Oni omogućuju modelu učenje složenijih odnosa među značajkama, uz primjenu tzv. *dropout* slojeva radi smanjenja prenaučenosti (*overfittinga*). Posljednji sloj mreže definiran je potpuno povezani sloj s prikladnom sigmoid aktivacijskom funkcijom, budući da se radi o zadatku binarne klasifikacije.

```
97:     model = models.Sequential([
98:         mobilenet,
99:         layers.GlobalAveragePooling2D(),
100:        layers.Dense(256, activation='relu'),
101:        layers.Dropout(0.4),
102:        layers.Dense(128, activation='relu'),
103:        layers.Dropout(0.3),
104:        layers.Dense(128, activation='relu'),
105:        layers.Dense(1, activation='sigmoid')
106:    ])
```

Programski kod 2 Kreiranje novog modela

S obzirom da početno treniranje svih slojeva često vodi u gubitak unaprijed naučenih značajki, implementiran je postupak finog podešavanja parametara (eng. *fine – tuning*). Tijekom treniranja, većina slojeva osnovnog modela ostala je zamrznuta (*layers.trainable = False*), dok je određen broj završnih slojeva ostavljen odmrznutim za dodatno treniranje. U konkretnom slučaju, za potrebe treninga su ostavljeni zadnji slojevi MobileNetV2 modela (oko 30 do 50 završnih slojeva,

ovisno o optimizaciji tog hiperparametra), čime je omogućena prilagodba modela na specifične obrasce prisutne u slikama bijelih krvnih stanica.

```
for layer in mobilenet.layers[:-30]: #zamrznuti svi osim posljednjih 30 slojeva
    layer.trainable = False
```

Programski kod 3 Zamrzavanje slojeva MobileNetV2 mreže

Primijenjena je augmentacija slika u obliku rotacija, translacija, uvećavanja (eng. *zoom*) i horizontalnih preslikavanja, čime se proširuje raznolikost podataka i time poboljšava generalizacijska sposobnost modela.

```
train_datagen = ImageDataGenerator(
    rescale=1./255,
    rotation_range=10,
    width_shift_range=0.1,
    height_shift_range=0.1,
    shear_range=0.1,
    zoom_range=0.1,
    horizontal_flip=True,
    fill_mode='nearest'
)
```

Programski kod 4 Definicija ImageDataGenerator za treniranje s augmentacijom slika

Kroz proces treniranja korištene su *callbacks* funkcije poput ranog zaustavljanja (eng. *Early Stopping*), smanjenja/redukcije koraka učenja (eng. *Reduce Learning Rate on Plateau*) i pohrane najbolje verzije modela (eng. *Model Checkpoint*).

```
early_stop = EarlyStopping(monitor='val_loss', patience=5,
restore_best_weights=True)
checkpoint = ModelCheckpoint("mobilenet_best_model.h5",
save_best_only=True)
reduce_lr = ReduceLROnPlateau(monitor='val_loss', factor=0.5,
patience=3)
```

Programski kod 5 *Checkpoints*

6. REZULTATI I ANALIZA MODELA

Rezultati i analiza modela daju uvid u kakvoću izgrađenog modela i njegove performanse izvršavanja tražene zadaće. Poglavlje će dati uvid u faze eksperimentiranja te optimizacije rada modela neuronske mreže.

Evaluacija modela strojnog učenja je najbitniji dio nakon provedenog treniranja, validacije i testiranja modela. U konkretnom slučaju problema klasifikacije bijelih krvnih stanica korištenjem sintetički generiranih podataka, cilj evaluacije jest utvrđivanje mogućnosti primjene umjetnih slika stanica za klasifikaciju stvarnih medicinskih uzoraka.

6.1. Opis eksperimentalnih faza

6.1.1. Lokalno treniranje na sintetičkim podacima

Nakon izgradnje modela, kao polazišna točka korišteni su samo sintetički podaci. Prvo je skup podijeljen na trening, validacijski i testni podskup u omjeru 80/10/10. Model je treniran i testiran, a na sljedećim slikama prikazani su najbolje postignuti rezultati u ovoj fazi eksperimentiranja.

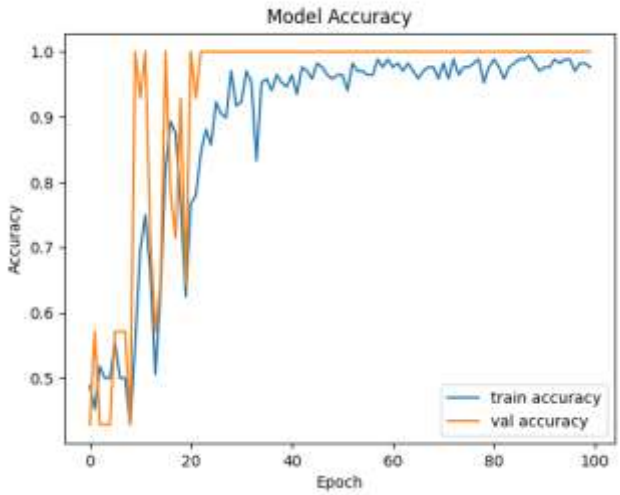

Slika 6. 1 Graf točnosti modela treniranog na sintetičkim slikama stanica

Na grafu točnosti modela možemo primijetiti kako se na trening skupu nakon 40 epoha već dobiva vrlo visoka točnost, a na validacijskom skupu model ima tendenciju ka prenaučenosti nakon 20 epoha.

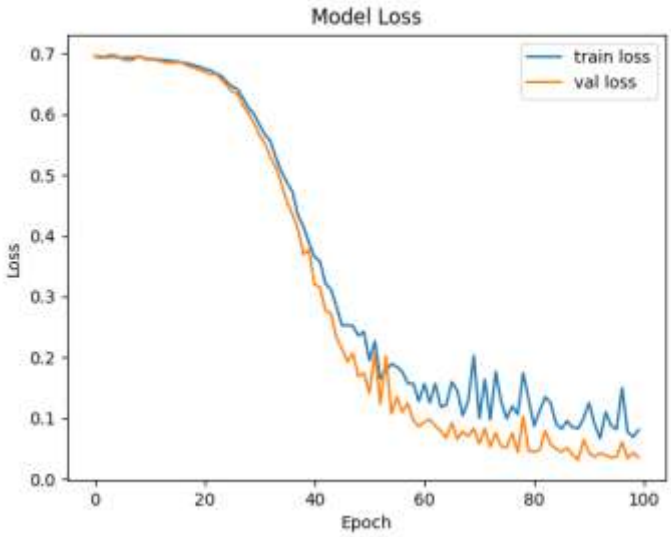

Slika 6. 2 Graf gubitaka modela treniranog na sintetičkim podacima

Graf gubitaka u ovom stadiju izgleda dosta optimistično, jer se pri kraju treninga i validacije dobivaju veoma dobri i prihvatljivi rezultati gubitaka.

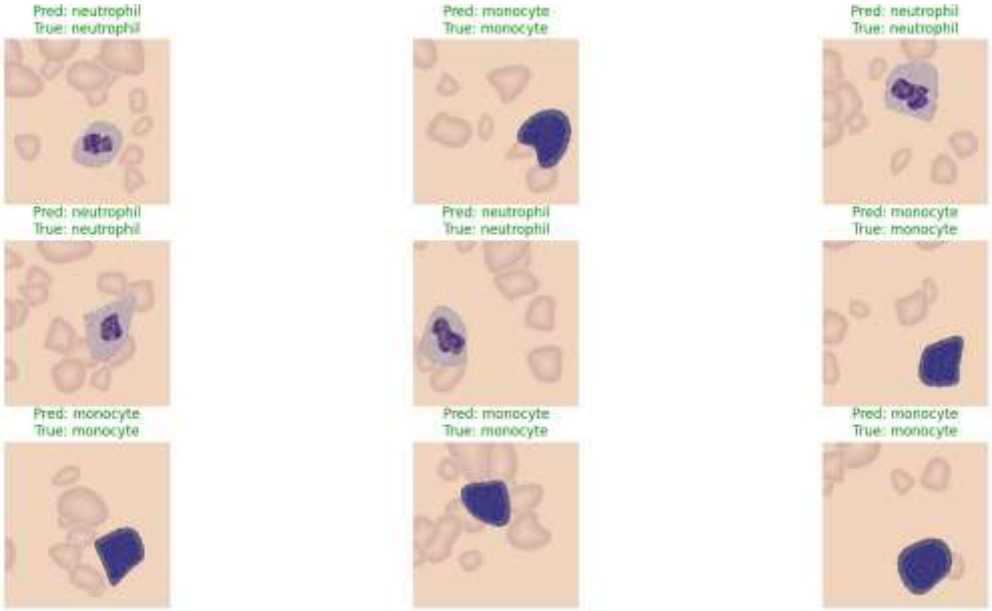

Slika 6. 3 Vizualizacija točnosti predikcija modela

Slika 6. 3 jasno prikazuje predikcije modela na nasumično izabranim uzorcima iz skupa podataka. Prva faza eksperimentiranja označava samo uvod u rad i inicijalni pregled ponašanja modela za dani problem. Kako bi se donijeli bolji zaključci potrebno je testirati model na stvarnim medicinskim podacima.

6.1.2. Testiranje na manjem skupu stvarnih slika

Sljedeća faza uključuje trening i validaciju na sintetičkim slikama, a testiranje na stvarnim medicinskim slikama uzoraka stanica. Bilo je potrebno pronaći vjerodostojne i što kvalitetnije slike stanica, ali u manjem opsegu. U tu svrhu korišten je dataset pod nazivom Blood Cell Images [18] koji sadrži oko 12 500 slika stanica podijeljenih u 4 klase. Zbog računalne i memorijske ograničenosti, izdvojeno je po 100 slika iz klase neutrofila i monocita, što čini mali skup, ali dovoljan za eksperiment i istraživanje. Kroz testiranje i treniranje modela mijenjani su hiperparametri *batch size* i broj epoha, kao i broj odmrznutih slojeva u MobileNetV2 mreži.

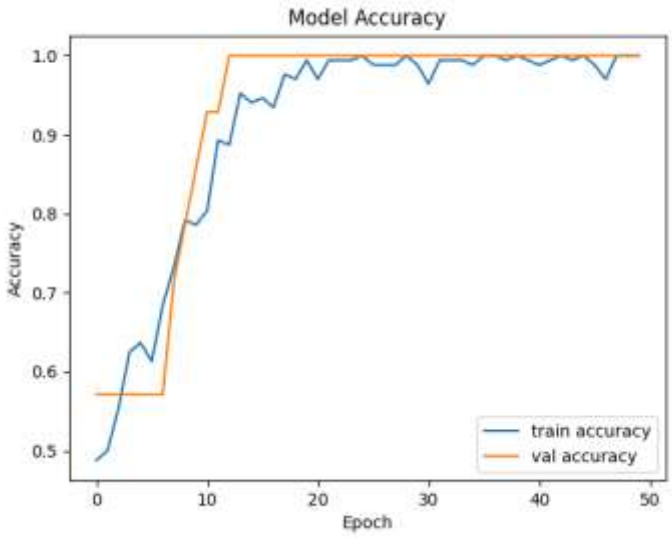

Slika 6. 4 Točnost modela treniranog na sintetičkim podacima

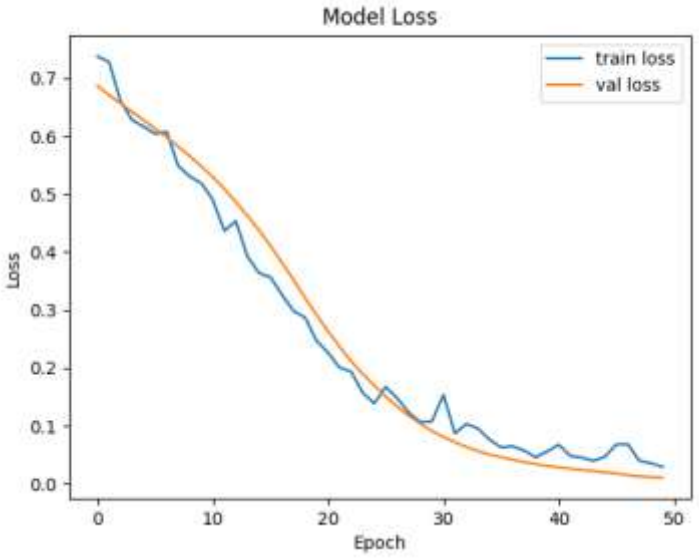

Slika 6. 5 Gubici modela treniranog na sintetičkim podacima

Usporedimo li rezultate treninga i validacije sa prethodnim rezultatima iz potpoglavlja 6.1.1. zamjetno je jednostavno smanjenje broja epoha na 50, jer iznad tog optimalnog broja model postaje sklon ka prenaučenosti, što naravno nije poželjno. Također na oba grafa krivulje treninga i validacije su se ustabilile bez naglih promjena s porastom broja epoha – model počinje bolje učiti značajke.

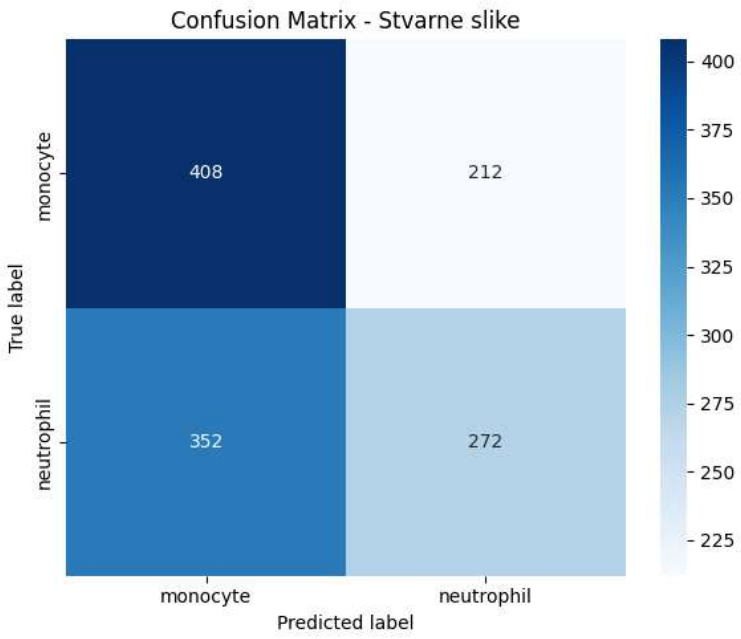

Slika 6. 6 Matrica zabune - stvarne slike

Metrika	**Vrijednost**
Točnost	0.52
Preciznost	0.53
Odziv	0.50
F1	0.51

Tablica 1Testiranje na manjem skupu stvarnih podataka

Testiranje na malom skupu stvarnih podataka donijelo je dosta niske rezultate za ovakvu vrstu problema. Iz prikaza matrice zabune proizlazi zaključak kako model ima tendenciju ka predviđanju stanica monocita u odnosu na neutrofile. Iz tablice metrika vidimo kako su klasifikacijske metrike prosječno na malo iznad 50% što nije dovoljno prihvatljivo za primjenu modela za stvarne probleme. Sintetički skup pokazao se nedovoljno reprezentativan za učenje stvarnih varijacija na medicinskim uzorcima iz laboratorija. U ovom stadiju pokazuje se ograničenje lokalnog testiranja na CPU osobnog računala i manjkavost opsežnosti skupova podataka. U tu svrhu sljedeća faza eksperimenta fokusirana je na prelazak u tzv. *cloud* treniranje i testiranje modela.

6.1.3. Cloud treniranje i testiranje

Za potrebe treninga i testa u cloud obliku korišteni su alati Google Colab i Google Disc te testni BCCD dataset, ali u ovom slučaju nije izdvojeno samo 200 uzoraka, nego su korišteni svi uzorci koji pripadaju klasama monocita i neutrofila.

Prvi rezultati koji su napravljeni radi finalne usporedbe i evaluacije modela dobiveni su na način da su realne slike stanica korištene i za treniranje i za test izgrađenog modela. U tom slučaju optimalan broj epoha se pokazao kao 5, a za *batch size* uzeto je po 16 uzoraka. Također, važno je napomenuti kako u ovom dijelu izvršenje svih faza je trajalo dosta duže nego kod korištenja samo sintetičkih podataka. Razloga je više, a najveći je taj što je korišten puno veći broj podataka, ali i stvarne slike stanica su složenije za analizu od sintetičkih.

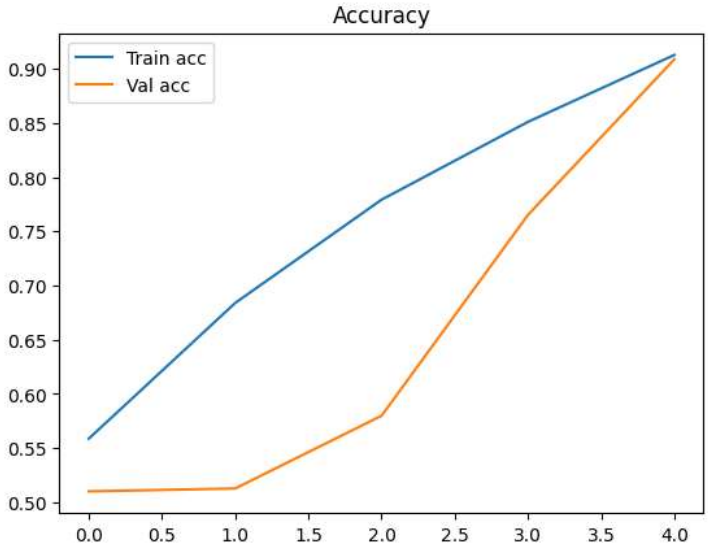

Slika 6. 7 Graf točnosti cloud treniranog modela na stvarnim slikama

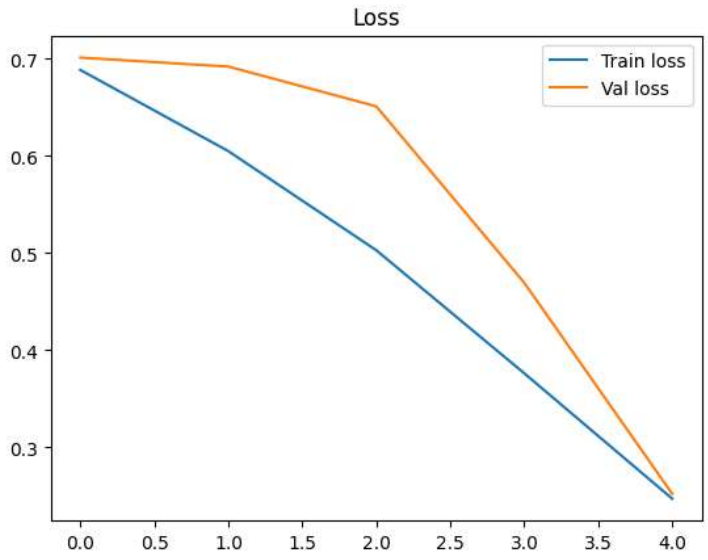

Slika 6. 8 Graf gubitaka cloud treniranog modela na stvarnim slikama

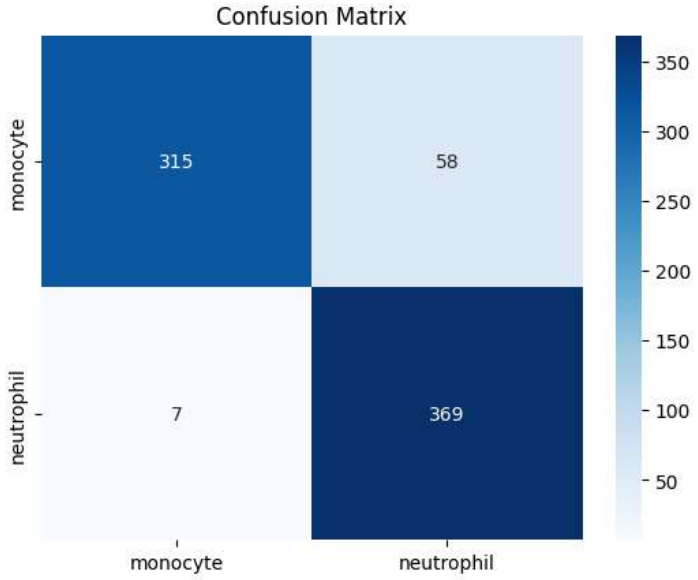

Slika 6. 9 Matrica zabune *cloud* testiranog modela na stvarnim slikama

Metrika	**Vrijednost**
Točnost	0.93
Preciznost	0.92
Odziv	0.93
F1	0.93

Tablica 2 *Cloud* treniranje i testiranje na stvarnim podacima

Nakon ove faze, uslijedilo je finalno cloud treniranje i validacija modela na generiranim sintetičkim slikama, a testiranje na stvarnim mikroskopskim slikama iz opsežnog dataseta.

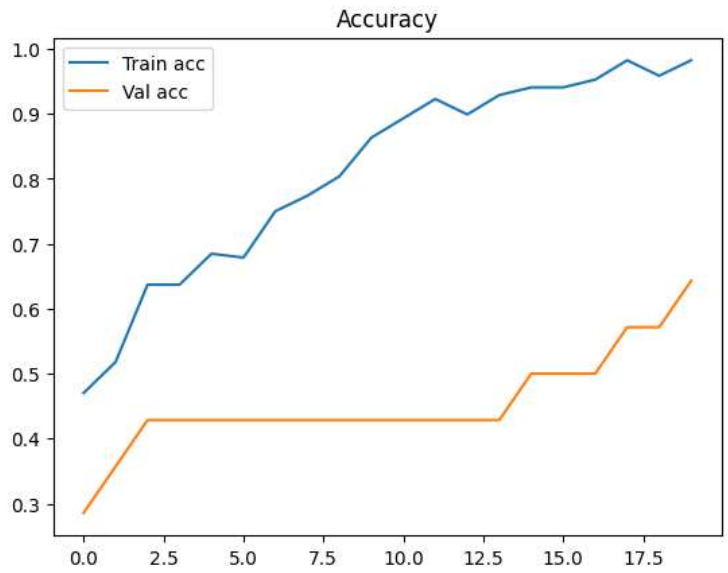

Slika 6. 10 Graf točnosti modela treniranog u *cloudu* na sintetičkim podacima

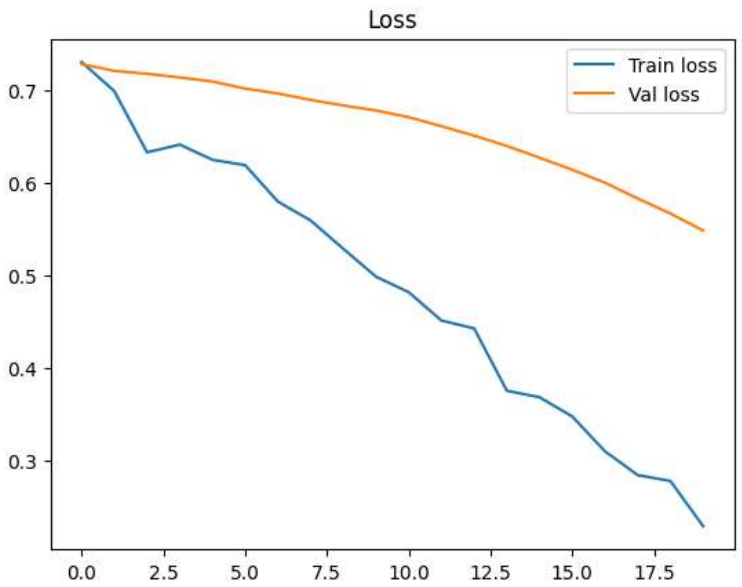

Slika 6. 11 Graf gubitaka modela treniranog u *cloudu* na sintetičkim podacima

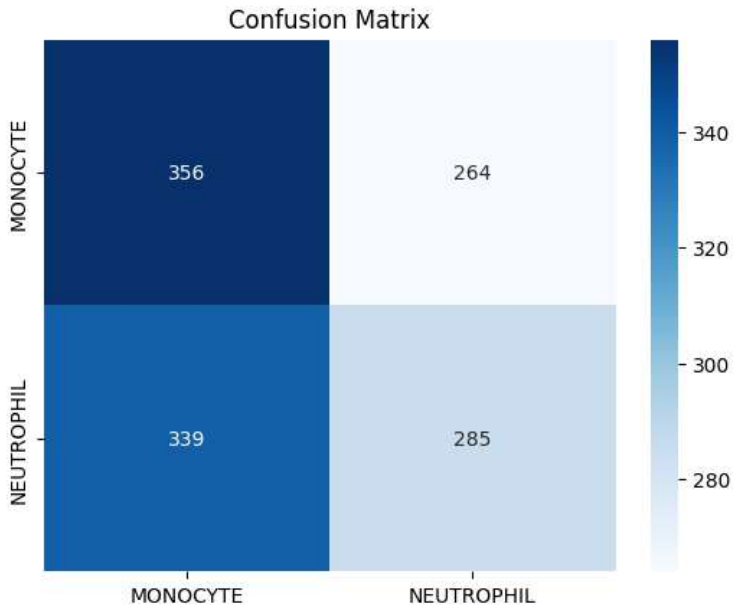

Slika 6. 12 Matrica zabune *cloud* testiranog modela na stvarnim podacima

Metrika	Vrijednost
Točnost	0.51
Preciznost	0.48
Odziv	0.42
F1	0.44

Tablica 3 *Cloud* treniranje na sintetičkim, testiranje na stvarnim podacima

Optimalan broj epoha se pokazao kao 20, a *batch size* je ostao na 16, u oba prethodno pokazana slučaja. Usporedimo li model koji je treniran lokalno i u cloudu na sintetičkim podacima, glavnu razliku čini promjena broja odmrznutih slojeva u mreži MobileNetV2 – kod lokalnog treniranja odmrznuti su svi osim zadnjih 30 slojeva, dok u cloud treniranju taj broj je promijenjen na 50. Treninzi i testiranje su sada smanjili vrijeme izvršenja i postali brži, s obzirom da smo sada radili sa sintetičkim podacima u fazi učenja kojih je puno manje u odnosu na prethodni slučaj treniranja za opsežnim skupom stvarnih slika.

6.2. Utjecaj parametara generiranja sintetičkih podataka

Kroz fazu eksperimentiranja, pokazalo se da kvaliteta i raznolikost sintetičkih podataka direktno utječu na mogućnost prepoznavanja realnih uzoraka stanica. Osim toga, primjenom agresivnije augmentacije na sintetičke slike, što je također odrađeno u cloud fazi eksperimentiranja pokazalo

se kao lošim utjecajem na rezultate te je donijelo nerealne varijacije na skupu. U ovakvom eksperimentu umjerena augmentacija donosi sasvim dovoljne varijacije čime su postignuti puno bolji rezultati.

Što se tiče broja epoha i broja odmrznutih slojeva u mreži korištenoj za prijenosno učenje, zamjetan je utjecaj na rezultate, ali ni optimizacija navedenih hiperparametara ne može u potpunosti nadoknaditi razliku između sintetičkog i realnog skupa.

6.3. Evaluacija robusnosti i generalizacije

Model je pokazao ograničenu sposobnost generalizacije na realne podatke nakon treniranja samo na sintetičkim slikama. Razlog tome leži u razlikama vizualnog izgleda realnih i sintetičkih slika u vidu kontrasta, pozadine i teksture stanica, koje značajno otežavaju klasifikaciju.

Također, uvidom u matrice zabune nakon faze eksperimentiranja, dovodi do zaključka kako dolazi do čestog miješanja dvaju klasa, što je čest problem kod morfološki sličnih stanica.

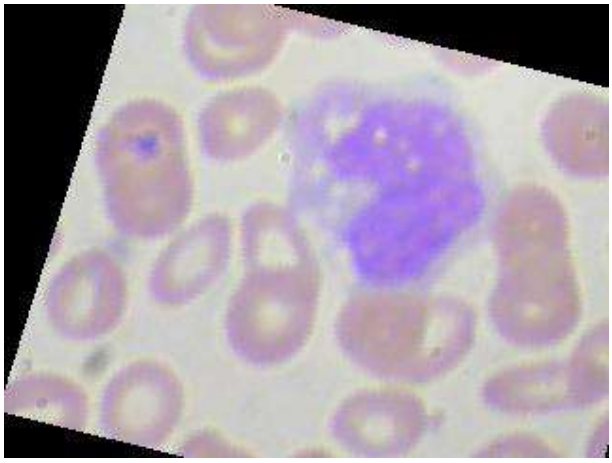

Slika 6. 13 Slika stvarnog mikroskopskog uzorka stanice monocita iz BCCD dataseta

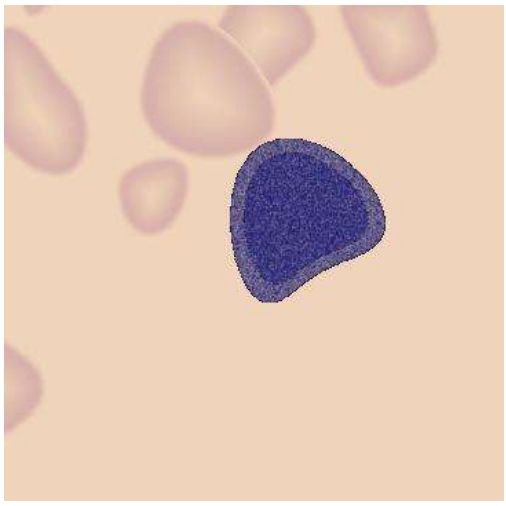

Slika 6. 14 Slika sintetičke stanice monocita

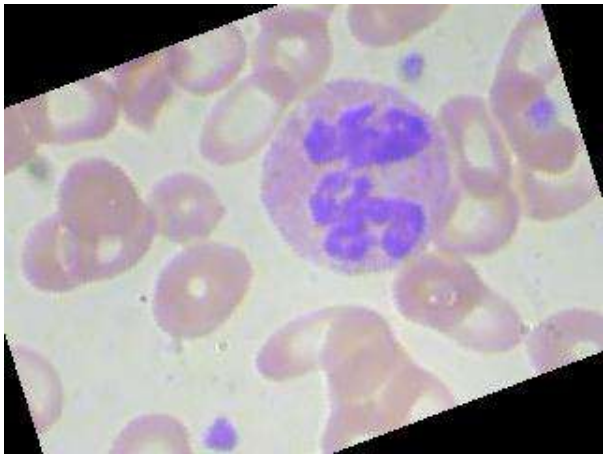

Slika 6. 15 Slika stvarne stanice neutrofila iz BCCD dataseta

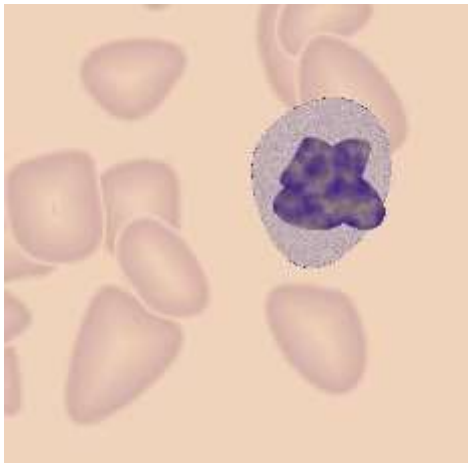

Slika 6. 16 Slika sintetičke stanice neutrofila

Vizualnom usporedbom korištenih uzoraka, možemo zaključiti kako osim nedostatka broja sintetičkih podataka, problem leži i u lošoj kvaliteti javno dostupnih uzoraka realnih slika stanica.

6.4. Prednosti i ograničenja sintetičkih podataka

Kao sumacija dosadašnjih zaključaka, slijede neke od prednosti i nedostataka korištenja sintetičkih podataka u svrhu klasifikacije bijelih krvnih stanica – neutrofila i monocita.

Prednosti su sljedeće:

- Omogućuje treniranje kod nedostatka realnih slika uzoraka stanica,
- Značajno povećavaju veličinu skupa za treniranje (generiranje sintetičkih slika algoritmom korištenim u ovom radu je efikasno, slike se dobiju jako brzo),
- Sintetički podaci korisni su za inicijalni razvoj modela.

Što se tiče ograničenja, ona uključuju sljedeće stavke:

- Umjetne slike nemaju kompletnu varijabilnost realnih uzoraka,
- Mogu inducirati *overfitting* (prenaučenost) na karakteristike specifične za generirane slike,
- Postoji ograničena mogućnost prelaska na stvarne medicinske uzorke bez dodatnog podešavanja.

7. ZAKLJUČAK

Glavne spoznaje koje proizlaze nakon detaljne analize provedenog zadatka uključuju različite aspekte koji utječu na konačni rezultat klasifikacije. Konkretno, sintetički podaci omogućuju inicijalni treniranje modela kada realnih uzoraka nema dovoljno, nisu javno dostupni ili nemaju dovoljnu kvalitetu. Model se pokazao iznimno uspješnim na velikim skupovima realnih podataka, ali u kombinaciji treninga na sintetičkim te evaluacije na stvarnim podacima, postoje određene manjkavosti. Prijenosno učenje kao netradicionalna metoda strojnog učenja pokazala se korisnom jer iskorištava prethodno naučene opće značajke slika. Međutim, bez dodatnih realnih podataka ostaju izražena ograničenja u generalizaciji modela. Važno je spomenuti kako testiranje robusnosti provedeno na samo dvije klase nije dovoljno. Realni klinički podaci često uključuju više klasa i složenije probleme za pomoć pri uspostavljanju dijagnoze. U budućem radu, sugerira se korištenje naprednih generativnih modela za stvaranje još kvalitetnijih sintetičkih slika koje bi bolje reprezentirale stvarnu biološku raznolikost. Osim toga, kombinacija sintetičkih i manjih skupova realnih podataka u procesu treniranja bi mogla donijeti bolje rezultate.

LITERATURA

[1]A.C. Guyton, J.E. Hall, Medicinska fiziologija (13. izdanje), Medicinska naklada, Zagreb, 2017. (poglavlje 34. - 35.)

[2]K. Abbas, J. Banks, V. Chandran, I. Tomeo-Reyes, Classification of White Blood Cell Types from Microscope Images: Techniques and Challenges, Formatex Research Center, Norristown, PA, SAD, 2018., dostupno na: https://www.researchgate.net/publication/327931984_Classification_of_White_Blood_Cell_Types_from_Microscope_ImagesTechniques_and_Challenges [10.5.2025.]

[3]L. Lin, W. Wang, B. Chen, Leukocyte recognition with convolutional neural network, Journal of Algorithms and Compotutional Technology, vol. 13, studeni, 2018. dostupno na: https://journals.sagepub.com/doi/epub/10.1177/1748301818813322 [10.5.2025.]

[4]R. Asghar, S. Kumar, P. Hynds, A. Shaukat, Classification of White Blood Cells Using Machine and Deep Learning Models: A Systematic Review, IEEE Journal of Biomedical and Health Informatics, dostupno na: https://arxiv.org/pdf/2308.06296 [10.5.2025.]

[5]T. Rosyadi, A. Arif, Nopriadi, B. Achmad, Faridah, Classification of leukocyte images using K - Means Clustering based on geometry features, 6th International Annual Engineering Seminar, str. 245. - 249., Yogyakarta, Indonezija, 2016., dostupno na: https://www.researchgate.net/publication/312561341_Classification_of_leukocyte_images_using_K-Means_Clustering_based_on_geometry_features [12.5.2025.]

[6] W. L. Tai, R. M. Hu, H. C. W. Hsiao, R. M. Chen, J. J. P. Tsai, Blood Cell Image Clasification Based on Hierarchical SVM, IEEE International Symposium on Multimedia, str. 129. - 136., Dana Point, California, SAD, 2011., dostupno na: https://www.researchgate.net/publication/221559041_Blood_Cell_Image_Classification_Based_on_Hierarchical_SVM [12.5.2025.]

[7] P. Yampri, C. Pintavirooj, S. Daochai, S. Teartulakarn, White Blood Cell Clasification based on the Combination of Eigen Cell and Parametric Feature Detection, 1st IEEE Conference on Industrial Electronics and Applications, str. 1. - 4., Singapur, 2006., dostupno na: https://ieeexplore.ieee.org/document/4025942 [12.5.2025.]

[8] J. Murel, E. Kavlakoglu, What is transfer learning?, Think 2024., IBM dostupno na: https://www.ibm.com/think/topics/transfer-learning#:~:text=Transfer%20learning%20is%20a%20machine,2 [19.6.2025.]

[9] M. Abadi, P. Barham, J. Chen, Z. Chen, A. Davis, J. Dean, M. Devin, S. Ghemawat, G. Irving, M. Isard, M. Kudlur, J. Levenberg, R. Monga, S. Moore, D. G. Murray, B.

Steiner, P. Tucker, V. Vasudevan, P. Warden, M. Wicke, Y. Yu, and X. Zheng, TensorFlow: A System for Large-Scale Machine Learning, Proceedings of the 12th USENIX Symposium on Operating Systems Design and Implementation, 2. – 4. studeni , 2016. , Savannah, GA, SAD. dostupno na: https://www.usenix.org/system/files/conference/osdi16/osdi16-abadi.pdf [19.6.2025.]

[10] F. Chollet, Keras: Deep Learning library for Theano and TensorFlow, 2015. dostupno na: https://keras.io [19.6.2025.]

[11] E. Bisong, Google Colaboratory. In Building Machine Learning and Deep Learning Models on Google Cloud Platform (str. 59. - 64.). Apress, Berkeley, CA, SAD, 2019. dostupno na: https://doi.org/10.1007/978-1-4842-4470-8_7 [19.6.2025.]

[12] Kaggle Inc. , Kaggle API Documentation., 2020. dostupno na: https://www.kaggle.com/docs/api [19.6.2025.]

[13] F. Pedregosa,G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, E. Duchesnay, Scikit-learn: Machine learning in Python. Journal of machine learning research, vol. 12., 2825-2830, 2011. dostupno na: https://www.jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf [19.6.2025.]

[14] J. D. Hunter, Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90-95., 2007. dostupno na: https://ieeexplore.ieee.org/document/4160265 [19.6.2025.]

[15] M. Waskom, seaborn: statistical data visualization. Journal of Open Source Software, 6(60), 3021., 2021. dostupno na: https://www.theoj.org/joss-papers/joss.03021/10.21105.joss.03021.pdf [19.6.2025.]

[16] K. Petrik, Sintetičko generiranje mikroskopskih slika krvnih stanica za potrebe treniranja neuronske mreže, diplomski rad, FERIT, Osijek, 2023.

[17] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, L. C. Chen, MobileNetV2: Inverted Residuals and Linear Bottlenecks. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 4510-4520, 2018. dostupno na: https://openaccess.thecvf.com/content_cvpr_2018/papers/Sandler_MobileNetV2_Inverted_Residuals_CVPR_2018_paper.pdf [19.6.2025.]

[18] Blood Cell Images dataset dostupno na: https://github.com/Shenggan/BCCD_Dataset [25.6.2025.]

ŽIVOTOPIS

Ivona Pranjić studentica je 3. godine prijediplomskog studija Elektrotehnika i informacijska tehnologija, smjer Informacijske i komunikacijske tehnologije na Fakultetu elektrotehnike, računarstva i informacijskih tehnologija u Osijeku. Prvu godinu studija upisala je akademske 2022./23. godine.

_____

Potpis autora

SAŽETAK

Klasifikacija bijelih krvnih stanica korištenjem sintetički generiranih podataka uspješno je provedena i analizirana u radu. Glavni cilj zadatka bio je uvidjeti koliko su sintetički podaci dobri u problemima koji uključuju klasifikaciju ljudskih stanica. Kroz teorijsku i tehničku pozadinu problema dan je uvid u područje koje povezuje računalne i medicinske grane znanosti. U praktičnom dijelu korištena je konvolucijska neuronska mreža u kombinaciji s metodom prijenosnog učenja korištenjem popularne neuronske mreže MobileNetV2. Provedenim eksperimentom i analizom donešeni su zaključci, kao i sugestije za buduće istraživanje u navedenom području.

Ključne riječi: strojno učenje, klasifikacija stanica, sintetički generirani podaci, prijenosno učenje

ABSTRACT

The classification of white blood cells using synthetically generated data was successfully performed and analyzed in the paper. The main goal of the task was to see how well synthetic data perform in problems involving human cell classification. Through the theoretical and technical background of the problem, an insight into the area that connects the computer and medical branches of science is given. In the practical part, a convolutional neural network was used in combination with the transfer learning method using the popular MobileNetV2 neural network. Conclusions and suggestions for future research in the mentioned area were made through the conducted experiment and analysis.

Key words: machine learning, cell classification, synthetically generated data, transfer learning

PRILOG: PROGRAMSKI KOD

```
import tensorflow as tf
from tensorflow.keras import layers, models
import matplotlib.pyplot as plt
import numpy as np
import os
from tensorflow.keras.preprocessing.image import ImageDataGenerator
from sklearn.metrics import classification_report, confusion_matrix,
accuracy_score, precision_score, recall_score, f1_score
import seaborn as sns

# Parametri
IMG_SIZE = 224
BATCH_SIZE = 20
EPOCHS_NUMBER=40
TRAIN_DIR = 'C:/Users/ZenBook/Završni rad/prave_slike_podijeljene/train'
VAL_DIR = 'C:/Users/ZenBook/Završni rad/prave_slike_podijeljene/val'
TEST_DIR = 'C:/Users/ZenBook/Završni rad/prave_slike_podijeljene/test'


monocyte_count = len(os.listdir(os.path.join(TRAIN_DIR, 'monocyte')))
neutrophil_count = len(os.listdir(os.path.join(TRAIN_DIR, 'neutrophil')))

print(f"Monocyte slike: {monocyte_count}")
print(f"Neutrophil slike: {neutrophil_count}")

# Definicija ImageDataGenerator za treniranje s augmentacijom
train_datagen = ImageDataGenerator(
    rescale=1./255,
    rotation_range=10,
    width_shift_range=0.1,
    height_shift_range=0.1,
    shear_range=0.1,
    zoom_range=0.1,
    horizontal_flip=True,
    fill_mode='nearest'
)

# ImageDataGenerator za validaciju i testiranje (bez augmentacije)
test_datagen = ImageDataGenerator(rescale=1./255)

# Generatori podataka
train_generator = train_datagen.flow_from_directory(
    TRAIN_DIR,
    target_size=(IMG_SIZE, IMG_SIZE),
    batch_size=BATCH_SIZE,
    class_mode='binary'
)
print("Class indices:", train_generator.class_indices)
from sklearn.utils.class_weight import compute_class_weight

# Pretvaranje generatora u numpy array (za class_weight funkciju)
train_labels = train_generator.classes  # ovo su 0 i 1

# Računanje težina
class_weights = compute_class_weight(
    class_weight='balanced',
    classes=np.unique(train_labels),
    y=train_labels
```

```
)

# Pretvaranje u dict (koji keras očekuje)
class_weights = dict(enumerate(class_weights))

print("Class weights:", class_weights)

validation_generator = test_datagen.flow_from_directory(
    VAL_DIR,
    target_size=(IMG_SIZE, IMG_SIZE),
    batch_size=BATCH_SIZE,
    class_mode='binary'
)

test_generator = test_datagen.flow_from_directory(
    TEST_DIR,
    target_size=(IMG_SIZE, IMG_SIZE),
    batch_size=1,  # bitno zbog prikaza pojedinačnih slika
    class_mode='binary',
    shuffle=True  # da miješa slike
)

# Kreiranje modela


from tensorflow.keras.applications import MobileNetV2
from tensorflow.keras.callbacks import EarlyStopping, ModelCheckpoint

# Učitavanje MobileNetV2 s pretreniranom težinom
mobilenet = tf.keras.applications.MobileNetV2(input_shape=(IMG_SIZE,
IMG_SIZE, 3),
                                              include_top=False,
                                              weights='imagenet')



for layer in mobilenet.layers[:-30]: #zamrznuti svi osim zadnjih 30 slojeva -
fine tuning
     layer.trainable = False

# Kreiranje novog modela
model = models.Sequential([
    mobilenet,
    layers.GlobalAveragePooling2D(),
    layers.Dense(256, activation='relu'),
    layers.Dropout(0.4),
    layers.Dense(128, activation='relu'),
    layers.Dropout(0.3),
    layers.Dense(128, activation='relu'),
    layers.Dense(1, activation='sigmoid')  # 2 klase: monocyte i neutrophil
])


# Kompajliranje modela s malim learning rate-om za fine-tuning

model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=1e-5),
              loss='binary_crossentropy',
              metrics=['accuracy',
                       tf.keras.metrics.Precision(name='precision'),
                       tf.keras.metrics.Recall(name='recall'),
```

```
                        tf.keras.metrics.AUC(name='auc')])#area under the
curve (roc krivulja)


model.summary()

# Callbacks
early_stop = EarlyStopping(monitor='val_loss', patience=5,
restore_best_weights=True)
checkpoint = ModelCheckpoint("mobilenet_best_model.h5", save_best_only=True)
reduce_lr = ReduceLROnPlateau(monitor='val_loss', factor=0.5, patience=3)

# Treniranje modela
epochs = EPOCHS_NUMBER
history = model.fit(
    train_generator,
    epochs=epochs,
    validation_data=validation_generator,
    callbacks=[early_stop, checkpoint],
    class_weight=class_weights

)


# Funkcija za crtanje grafova:
def plot_history(history):
    plt.plot(history.history['accuracy'], label='train accuracy')
    plt.plot(history.history['val_accuracy'], label='val accuracy')
    plt.title('Model Accuracy')
    plt.xlabel('Epoch')
    plt.ylabel('Accuracy')
    plt.legend()
    plt.show()

    plt.plot(history.history['loss'], label='train loss')
    plt.plot(history.history['val_loss'], label='val loss')
    plt.title('Model Loss')
    plt.xlabel('Epoch')
    plt.ylabel('Loss')
    plt.legend()
    plt.show()

plot_history(history)

# Predikcije
pred_probs = model.predict(test_generator)
y_pred = (pred_probs > 0.5).astype(int).flatten()
y_true = test_generator.classes
class_labels = list(test_generator.class_indices.keys())


# Evaluacija na testnim podacima(generiranih slika):
results = model.evaluate(test_generator)
for name, value in zip(model.metrics_names, results):
    print(f"{name}: {value:.4f}")

# Prikaz rezultata za 9 testnih (sintetičkih) slika:
class_names = list(test_generator.class_indices.keys())

plt.figure(figsize=(10, 10))
for i in range(9):
```

```
    img, label = test_generator[i]
    prediction = model.predict(img)
    predicted_class = class_names[1 if prediction[0] > 0.5 else 0]
    true_class = class_names[int(label[0])]

    correct = predicted_class == true_class
    color = 'green' if correct else 'red'


    plt.subplot(3, 3, i+1)
    plt.imshow(img[0])
    plt.axis('off')
    plt.title(f'Pred: {predicted_class}\nTrue: {true_class}', color=color)

plt.tight_layout()
plt.show()

# Metrike
acc = accuracy_score(y_true, y_pred)
prec = precision_score(y_true, y_pred, average='macro')
rec = recall_score(y_true, y_pred, average='macro')
f1 = f1_score(y_true, y_pred, average='macro')
print("Točnost (Accuracy):", round(acc, 4))
print("Preciznost (Precision):", round(prec, 4))
print("Odziv (Recall):", round(rec, 4))
print("F1-mjera:", round(f1, 4))

# Matrica zabune
cm = confusion_matrix(y_true, y_pred)
plt.figure(figsize=(6, 5))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', xticklabels=class_labels,
yticklabels=class_labels)
plt.xlabel('Predicted label')
plt.ylabel('True label')
plt.title('Confusion Matrix - Stvarne slike')
plt.tight_layout()
plt.show()
```